

Базы данных


Тема 14

Логические модели баз данных

История развития баз данных

- крупные БД (системы обработки транзакций масштаба крупных организаций) → настольные БД → сетевые БД → интернет:
 - до 1970-х – переход от ведения записей вручную к системам обработки файлов (file-processing systems);
 - 1970-1980 – появление первых баз данных (dBase, ADABAS, Total, System2000, IDMS, IMS);
 - 1978-1985 – появление реляционных баз данных (DB2, Oracle);
 - 1982-1992 – развитие баз данных для настольных компьютеров (dBase-II, Paradox, Access, dBase-IV, FoxPro);
 - 1985-2000 – появление и развитие объектно-ориентированных баз данных;
 - 1995-н.в. – интеграция технологий баз данных и интернет-технологий (в т.ч. NoSQL);

Базы данных и технологические платформы





Логические модели баз данных

- логическая модель (*logical data model, information model*) базы данных определяет:
 - набор поддерживаемых типов структур данных;
 - набор допустимых операций над поддерживаемыми структурами данных;
 - набор общих правил целостности данных, явно или неявно определяющих корректные состояния базы данных или их изменения;
- модели баз данных:
 - иерархическая (*hierarchical model*);
 - сетевая (*network model*);
 - реляционная (*relational model*);
 - объектно-ориентированные (*object-oriented model*);
 - пост-реляционные модели, NoSQL (Not only SQL) базы данных:
 - хранилища ключей и значений (*KV-store, key-value store, KVP, key-value pairs*);
 - документо-ориентированные базы данных (*document-oriented databases*);
 - графовые базы данных (*graph databases*);
 - столбцовые базы данных (*column store, wide-column store*);
 - временные базы данных (*time-series databases*);
- ряд СУБД поддерживают несколько логических моделей данных.

Иерархическая и сетевая модели

- иерархическая модель (hierarchical model) – модель данных, в которой данные представляют собой древовидную структуру;
 - пример: реестр Windows (Windows Registry);
- сетевая модель (network model) – модель данных с сетевой структурой, возможно наличие циклов (как на уровне модели данных, так и на уровне самих данных).



Реляционная модель

- реляционная модель (*relational database model*)
 - введена в 1970г. Э.Ф.Коддом (E.F.Codd, A Relational Model of Data for Large Shared Databanks);
 - основана на применении концепции реляционной алгебры к проблеме хранения больших объемов данных;
 - определяет способ хранения данных в виде таблиц со строками и столбцами, при этом минимизируется дублирование и исключаются определенные типы ошибок обработки;
 - дает стандартный способ структурирования и обработки данных;
- нормализация (*normalization*) – последовательность преобразований, обеспечивающих определенный набор требований.

EmpNum	EmpName	DeptNum	DeptName
100	Jones	10	Accounting
150	Lau	20	Marketing
200	McCauley	10	Accounting
300	Griffin	10	Accounting

(a) One-Table Design

OR?

DeptNum	DeptName
10	Accounting
20	Marketing

EmpNum	EmpName	DeptNum
100	Jones	10
150	Lau	20
200	McCauley	10
300	Griffin	10

(b) Two-Table Design


Отношение

- отношение (*relation*) – двумерная таблица, обладающая следующими свойствами:
 - каждая строка содержит данные, описывающие некоторую сущность или ее часть;
 - каждый столбец представляет один из атрибутов сущности;
 - каждая ячейка содержит одиночное значение;
 - все значения в одном столбце имеют один и тот же тип;
 - каждый столбец имеет уникальное имя;
 - не важен порядок строк;
 - не важен порядок столбцов;
 - не может существовать двух идентичных строк.

Объектно-ориентированные базы данных

- object-oriented programming, объектно-ориентированное программирование (конец 1980х);
- объектно-ориентированные СУБД, object-oriented DBMS – предназначены для прозрачной и унифицированной обработки структур данных ООП, так как реляционная модель для этого не вполне подходит:
 - сложность переноса накопленных данных;
 - не обладают достаточной универсальностью (редкой является реализация поддержки наследования);
 - примеры: Cache, ObjectDB;
- Oracle: object-relational databases;
- системы ORM (*Object-relational mapping*, объектно-реляционное отображение) – системы преобразования объектов (в терминах ООП) в форму, которая подходит для их хранения в файлах и базах данных:
 - примеры: NHibernate.

Объектно-ориентированные базы данных → ORM (Object-Relational Mapping)



Постреляционные СУБД: предпосылки

- реляционные базы данных в первую очередь ориентированы на обработку транзакций, то есть выполнение большого числа незначительных (относительно общего объёма хранимой информации) модификаций данных:
 - строчная организация физического хранения данных;
 - применение строгих механизмов обеспечения свойств атомарности, согласованности, изоляции и отказоустойчивости транзакций (англ. ACID – *Atomicity, Consistency, Isolation, Durability*);
- теорема CAP (*Consistency, Availability, Partition Tolerance*): в распределённой компьютерной системе невозможно постоянно и строго гарантировать выполнение свойств согласованности, доступности и устойчивости к потере связи между узлами:
 - *согласованность* означает получение в каждый момент времени одинаковых данных всеми пользователями, осуществляющими их чтение;
 - *доступность* означает возможность пользователя выполнить операцию в конкретный момент времени;
 - *устойчивость к потере связности* – полное или частичное сохранение работоспособности хранилища в случае разрыва соединения между различными группами его узлов (учитывая необходимость обеспечить заданное время отклика при высокопроизводительной обработке данных).

Реляционные базы данных: хранение

Block	ID	Name	DOB	Salary	Sales	Expenses
1	1001	Dick	21/12/1960	67,000	78980	3244
2	1002	Jane	12/12/1955	55,000	67840	2333
3	1003	Robert	17/02/1980	22,000	67890	6436
4	1004	Dan	15/03/1975	65,200	98770	2345
5	1005	Steven	11/11/1981	76,000	43240	3214

Row-oriented storage

ID	Name	DOB	Salary	Sales	Expenses
1001	Dick	21/12/1960	67,000	78980	3244
1002	Jane	12/12/1955	55,000	67840	2333
1003	Robert	17/02/1980	22,000	67890	6436
1004	Dan	15/03/1975	65,200	98770	2345
1005	Steven	11/11/1981	76,000	43240	3214

Tabular data

Columnar storage

Block	Dick	Jane	Robert	Dan	Steven
1					
2	21/12/1960	12/12/1955	17/02/1980	15/03/1975	11/11/1981
3	67,000	55,000	22,000	65,200	76,000
4	78980	67840	67890	98770	43240
5	3244	2333	6436	2345	3214

Block	ID	Name	DOB	Salary	Sales	Expenses
1	1001	Dick	21/12/1960	67,000	78980	3244
2	1002	Jane	12/12/1955	55,000	67840	2333
3	1003	Robert	17/02/1980	22,000	67890	6436
4	1004	Dan	15/03/1975	65,200	98770	2345
5	1005	Steven	11/11/1981	76,000	43240	3214

Storage in row format

```
SELECT SUM(salary)
FROM saleperson
```

Storage in columnar format

Block	Dick	Jane	Robert	Dan	Steven
1					
2	21/12/1960	12/12/1955	17/02/1980	15/03/1975	11/11/1981
3	67,000	55,000	22,000	65,200	76,000
4	78980	67840	67890	98770	43240
5	3244	2333	6436	2345	3214

Block	ID	Name	DOB	Salary	Sales	Expenses
1	1001	Dick	21/12/1960	67,000	78980	3244
2	1002	Jane	12/12/1955	55,000	67840	2333
3	1003	Robert	17/02/1980	22,000	67890	6436
4	1004	Dan	15/03/1975	65,200	98770	2345
5	1005	Steven	11/11/1981	76,000	43240	3214

Row-oriented storage


```
INSERT INTO saleperson
```

Columnar storage

Block	Dick	Jane	Robert	Dan	Steven
1					
2	21/12/1960	12/12/1955	17/02/1980	15/03/1975	11/11/1981
3	67,000	55,000	22,000	65,200	76,000
4	78980	67840	67890	98770	43240
5	3244	2333	6436	2345	3214

Постреляционные СУБД

- восполняют недостаток функциональности в традиционных (реляционных СУБД)
 - хранилища ключей и значений (KV-store, key-value store, KVP, key-value pairs);
 - документо-ориентированные (document-oriented model);
 - графовые базы данных (graph databases);
 - столбцовые базы данных (column store, wide-column store);
 - временные базы данных (time-series databases);
- многостороннее хранение (polyglot persistence).




Хранилища ключей и значений

- KV-store, key-value store (KVP, key-value pairs);
- хранилища сопоставляют значения ключам;
- примеры: Redis, Memcached, Amazon DynamoDB, Riak KV, Aerospike // memcached (memcachedb, membase), MS Velocity, Tokyo Cabinet, MongoDB, Tarantool, Apache Cassandra, Google BigTable;
- дополнительные возможности:
 - поддержка различных типов значений: текст, изображения, XML-документы, составные типы данных (например, списки, отсортированные множества)
- могут рассматриваться более сложные способы организации данных на уровне хранения (тройки /triplestore//subject-predicate-object, entity-attribute-value model/ и т.д.).

Key	Value
K1	AAA,BBB,CCC
K2	AAA,BBB
K3	AAA,DDD
K4	AAA,2,01/01/2015
K5	3,ZZZ,5623

Документо-ориентированные базы данных: пример документа (JSON)



Документо-ориентированные базы данных


- документо-ориентированные базы данных (document-oriented databases) предназначены для хранения и обработки документо-ориентированной (полуструктурированной, semi-structured) информации;
- основаны на понятии *документа*, как сущности, включающей в себя некоторый набор данных, закодированных в стандартных форматах (XML, YML, JSON, BSON, PDF, MS Office);
- документы могут содержать вложенные структуры;
- каждый из документов может содержать в себе как общие для некоторого набора документов поля, так и уникальные, что делает структуру документа более гибкой по сравнению с реляционной моделью;
- база данных предоставляет средства извлечения документов (document retrieval) на основе содержимого документов (content) в виде API или языка запросов (query language);
- примеры: CouchDB, MongoDB, MarkLogic, Amazon DynamoDB, LotusNotes, OrientDB, ...

Столбцовые базы данных


- столбцовые базы данных (column-oriented databases) ориентированы на хранение данных по столбцам, в отличие от реляционных баз данных (хранение по строкам):
 - несущественные накладные расходы на добавление нового столбца к уже существующим данным;
 - гибкость схемы данных (набор столбцов у различных строк может быть разным);
 - возможна высокая степень сжатия данных для столбцов с повторяющимися значениями;
- примеры: Apache HBase, Apache Cassandra, Accumulo, Google BigTable, ...

	INFO column Family	FRIENDS column Family												
Rowkey=Guy	<table><tr><td>Name</td></tr><tr><td>Guy Harrison</td></tr></table>	Name	Guy Harrison	<table><tr><td>Jo</td><td>John</td></tr><tr><td>jo@gmail</td><td>john@hotmail</td></tr></table>	Jo	John	jo@gmail	john@hotmail						
Name														
Guy Harrison														
Jo	John													
jo@gmail	john@hotmail													
Rowkey=Jo	<table><tr><td>Name</td></tr><tr><td>Joanna S</td></tr></table>	Name	Joanna S	<table><tr><td>John</td><td>Paul</td><td>Ringo</td><td>George</td></tr><tr><td>john@hotmail</td><td>paul@yahoo</td><td>ringo@aol</td><td>george@gmail</td></tr></table>	John	Paul	Ringo	George	john@hotmail	paul@yahoo	ringo@aol	george@gmail		
Name														
Joanna S														
John	Paul	Ringo	George											
john@hotmail	paul@yahoo	ringo@aol	george@gmail											

Графовые данные



Графовые данные в реляционной СУБД



```
1 SELECT p2.personname, m1.movieName
2 FROM people p1
3      JOIN actors a1 ON (p1.personid = a1.personid)
4      JOIN movies m1 ON (a1.movieid = m1.movieid)
5      JOIN actors a2 ON (a2.movieid = m1.movieid)
6      JOIN people p2 ON (p2.personid = a2.personid)
7 WHERE p1.personname = 'Keanu Reeves';
8
```

Графовые базы данных

- графовые базы данных (*graph databases*) предназначены для хранения структуры графа: узлов и связей между ними;
- как с узлами, так и со связями могут быть ассоциированы свойства (атрибуты), представляющие собой пару ключ-значение и позволяющие хранить дополнительные данные;
- язык запросов или API графовых баз данных, а также оптимизация производительности ориентированы на предоставление возможности максимально удобного и быстрого обхода узлов по связям (поиск в ширину, нахождение подграфов и т.д.);
- примеры: Neo4j, OrientDB, AllegroGraph, HypergraphDB, FlockDB, DEX, SonesDB ...
- реализации вычислительных библиотек (*graph computing engines*) для выполнения графовых операций в хранилищах данных различных типов (Apache Giraph, Titan, Apache GraphX, Oracle Graph)

Вопросы к экзамену

- Модели баз данных: иерархическая и сетевая модели, реляционная модель. Построчное и столбцовое хранение в реляционных СУБД.
- Модели баз данных: обзор постреляционных моделей (объектно-ориентированные базы данных, хранилища ключей и значений, документо-ориентированные, графовые и столбцовые базы данных).